

1. 도입 (2분) - 발표 대본

프로젝트 소개

"안녕하세요, 저희 프로젝트 J-StockLab을 소개해 드리겠습니다. J-StockLab은 일본 Nikkei 225 지수의 상위 20개 종목을 대상으로 1일부터 7일 후까지의 주가를 예측하는 딥러닝 기반 주식 예측 시스템입니다. 단순히 모델 하나를 만드는 것에 그치지 않고, 3가지 서로 다른 모델을 비교 분석하고, 실험을 통해 검증한 뒤, 최종적으로 실제 사용 가능한 웹 서비스로 구현하는 것까지 진행했습니다."

문제 정의: 왜 일본 주식시장인가?

"먼저, 왜 일본 주식시장을 선택했는지 말씀드리겠습니다. 첫째, 아시아 최대 규모의 주식시장입니다. 세계 거래소연맹 기준으로 미국의 나스닥, 뉴욕, 유럽에 이어 세계 4위이며, 아시아에서는 가장 큰 규모를 자랑합니다. 둘째, 국내에서 일본 주식시장 정보에 접근하기가 쉽지 않습니다. 현재 일본 주식 관련 거시경제 지표나 주가 정보, 예측 서비스를 제공하는 플랫폼은 investing.com이나 TradingView 정도에 불과합니다. 한국어 기반의 접근성 높은 서비스는 거의 전무한 실정입니다. 셋째, 이러한 상황에서 국내 투자자들이 일본 증권시장에 관심을 갖고 투자 기회를 모색하기에는 정보 접근의 장벽이 높습니다. 저희는 이 장벽을 낮추고, 국내 투자자들이 일본 시장에 대한 투자 기회를 확대할 수 있는 환경을 조성하고자 했습니다."

문제 정의: 주가 예측이 왜 어려운가?

"그렇다면 주가 예측은 왜 어려울까요? 첫째, 비선형성입니다. 주가는 단순한 선형 관계로 설명되지 않습니다. 복잡한 패턴이 얹혀 있습니다. 둘째, 노이즈가 많습니다. 뉴스, 심리, 예측 불가능한 이벤트 등 주가에는 수많은 잡음이 섞여 있습니다. 셋째, 외부 요인의 영향이 큼니다. 금리, 환율, 글로벌 경제 상황 등 개별 기업 외적인 요소들이 주가에 큰 영향을 미칩니다. 저희가 이 모든 문제를 완벽하게 해결할 수는 없지만, 특히 세 번째 문제인 외부 요인에 주목하여 경제 지표를 함께 활용하면 예측 정확도를 높일 수 있지 않을까? 라는 가설을 세우고 나름대로 실험을 진행해 보았습니다."

프로젝트 목표

"이러한 배경을 바탕으로 저희가 세운 프로젝트 목표는 세 가지입니다. 첫째, 3가지 모델로 주가 예측. Linear Regression, LSTM, Transformer 세 가지 모델을 구현하고 비교합니

다. 둘째, 실험을 통한 모델 검증. 단순히 정확도만 보는 것이 아니라, Bias-Variance 분석과 Hyperparameter Tuning을 통해 모델의 신뢰성을 검증합니다. 셋째, 확장 과제를 실제 웹 서비스화. 예측 결과를 누구나 쉽게 확인할 수 있는 웹 대시보드를 구축합니다. 지금부터 이 목표들을 어떻게 달성했는지 순서대로 설명드리겠습니다."

2. 데이터 (2분) - 발표 대본 (보강)

데이터 소스 (FRED API + yfinance)

"이제 저희가 어떤 데이터를 사용했는지 설명드리겠습니다. 데이터는 크게 두 가지 소스에서 수집했습니다. 첫 번째는 FRED API입니다. FRED는 미국 세인트루이스 연방준비은행에서 제공하는 경제 데이터베이스로, 일본과 미국의 거시경제 지표 18개를 수집했습니다. 두 번째는 yfinance입니다. Yahoo Finance의 데이터를 가져오는 파이썬 라이브러리로, 시장 지표 9개와 개별 종목 주가 20개를 수집했습니다. 수집 기간은 **2014년 10월 16일부터 현재까지**입니다. 이 시작일은 예측 대상 종목 중 가장 늦게 상장한 리크루트 홀딩스의 상장일을 기준으로 설정했습니다. 총 데이터는 **약 4,000행 이상이며**, 거래일 기준으로 일별 갱신됩니다."

27개 경제지표 선정 이유

"저희가 선정한 경제지표는 총 **27개**입니다. 세 가지 카테고리로 나눌 수 있습니다. **첫째, 일본 경제지표 8개**입니다.

실질 GDP, 실업률, 10년 국채 수익률, 은행간 금리, 산업생산, 무역지수, 소비자 신뢰지수, 일본은행 총자산 등 일본 내수 경제 상황을 반영하는 지표들입니다. **둘째, 미국 경제지표 10개**입니다.

기대 인플레이션율, 장단기 금리차, 기준금리, 국제 수익률, 소비자 심리지수, 실업률, 소비자 물가지수, GDP 성장률, 금융스트레스지수 등입니다. 미국 경제지표를 포함한 이유는 미국의 금리정책과 경제 상황의 변화율을 통해 일본 주가에 구조적인 영향을 미치기 때문입니다. **셋째, 시장 지표 9개**입니다.

닛케이 225, 닛케이 300, TOPIX ETF 같은 일본 지수와 S&P 500, 나스닥 같은 미국 지수, 그리고 VIX 지수, 금 가격, 달러 인덱스, 엔/달러 환율 등 시장 심리와 글로벌 자금 흐름을 반영하는 지표들입니다. 이렇게 **일본 내부 요인과 글로벌 요인을 모두 고려하여** 경제지표를 선정했습니다."

20개 종목 선정 기준

"예측 대상 종목은 **Nikkei 225** 지수 내 **시가총액 상위 20개 종목**으로 선정했습니다. Toyota, Sony, SoftBank Group, Nintendo, Fast Retailing 등 일본을 대표하는 대형주들입니다. 시가총액 상위 종목을 선택한 이유는 **거래량이 충분하고, 데이터 품질이 안정적**이기 때문입니다. 소형주의 경우 거래량 부족으로 인한 가격 왜곡이 발생할 수 있어 제외했습니다. 또한 20개 종목은 금융, IT, 제조, 유통 등 **다양한 산업군을 포함하고 있어 시장 전반의 흐름을 파악하기에 적합**합니다."

데이터 전처리

"수집한 데이터는 다음과 같은 전처리 과정을 거쳤습니다.

첫째, 데이터 빈도 통일입니다. 원본 데이터는 수집 주기가 상이합니다. 국채 수익률이나 주가 지수는 일간 데이터이지만, 금융스트레스지수는 주간, 실업률이나 기준금리는 월간, GDP는 분기 데이터입니다. 이러한 상이한 빈도의 데이터들을 **Forward Fill 방식으로 일간 데이터로 통일**했습니다. Forward Fill을 사용한 이유는 경제지표가 발표 시점까지 이전 값이 유효하다고 가정하였기 때문입니다. 예를 들어 분기 GDP가 4월에 발표되면, 해당 값은 7월 다음 발표일까지 유효하므로 동일한 값을 적용하는 것이 경제적으로 타당하다고 생각했습니다.

둘째, 결측치 처리입니다. 결측치는 세 단계로 처리했습니다. 먼저 FRED API에서 결측을 의미하는 마침표 값을 NaN으로 변환했습니다. 다음으로 Forward Fill을 적용하여 이전 값으로 결측치를 채우고, 데이터 시작 부분의 결측치는 Backward Fill로 이후 값을 사용하여 채웠습니다. 마지막으로 핵심 지표에 여전히 결측치 있는 행만 제거했습니다. 여기서 **처리 순서가 중요합니다.** dropna를 먼저 실행하면 월간 데이터의 경우 최근 발표 이후 값이 없는 행이 모두 삭제되어 상당한 데이터 손실이 발생합니다. 따라서 반드시 ffill, bfill을 먼저 적용한 후 dropna를 실행해야 합니다.

셋째, 정규화입니다. 딥러닝 모델의 학습 안정성과 수렴 속도를 위해 MinMaxScaler를 사용하여 모든 피처를 0에서 1 사이로 정규화했습니다. 중요한 점은, **주가 데이터와 경제 지표 데이터에 별도의 스케일러를 적용했다는 것**입니다. 주가는 수백에서 수만 단위의 값을 가지는 반면, 금리나 실업률은 0에서 5 사이의 작은 값을 갖습니다. 동일한 스케일러를 적용하면 값이 작은 경제지표의 정보가 손실될 수 있으므로, 각각의 스케일러를 적용하여 데이터 특성을 보존했습니다. 전처리를 마친 최종 데이터셋은 **약 4,063행, 48개 컬럼**으로 구성되며, 결측치는 존재하지 않습니다."

EDA: 상관관계 분석

"전처리를 마친 후, 저희의 핵심 가설을 검증하기 위해 탐색적 데이터 분석을 수행했습니다. 핵심 가설은 **거시경제 지표가 주가 변동에 유의미한 영향을 미친다**는 것입니다. 이를 검증하기 위해 27개 경제지표와 20개 종목 간의 상관관계를 분석했습니다. 화면에 보이는 히트맵이 그 결과입니다.

분석 결과, **전체 평균 절대 상관계수는 0.611**로 경제지표와 주가 간에 중간 이상의 상관관계가 존재함을 확인했습니다. 최대 상관계수는 0.986, 최소는 -0.834로 강한 양의 상관관계와 음의 상관관계가 모두 관찰되었습니다.

몇 가지 흥미로운 발견이 있었습니다. **첫째, 시장 지표와의 강한 동조화입니다.**

닛케이 225, S&P 500, 나스닥 등 시장 지수는 거의 모든 종목과 강한 양의 상관관계를 보였습니다. 글로벌 주식시장이 함께 움직인다는 것을 보여줍니다.

둘째, 금리 지표와 금융주의 특수한 관계입니다.

일본 10년 국채 수익률은 Mitsubishi UFJ Financial과 0.965의 상관계수를 보였습니다. 금리 상승이 금융기관의 이자 마진 확대에 이어지기 때문입니다.

셋째, 종목별로 상이한 패턴입니다.

Toyota는 닛케이 300과 0.958, Sony는 S&P 500과 0.979, SoftBank는 금 가격과 0.861의 상관관계를 보여, 종목마다 영향을 받는 지표가 다름을 확인했습니다.

이 분석 결과는 **경제지표가 주가 예측에 유의미한 정보를 제공할 수 있음**을 시사합니다. 그리고 이것이 저희가 다음에 설명드릴 Dual Input Stream 아키텍처를 설계한 근거가 되었습니다."

Dual Input Stream 설계 철학

"이제 저희가 설계한 모델 아키텍처에 대해 설명드리겠습니다. **앞선 상관관계 분석에서 확인했듯이, 경제지표와 주가 간에 평균 0.611의 상관관계가 존재하고, 종목별로 영향을 받는 지표가 다르다**는 것을 확인했습니다. 이 분석 결과를 바탕으로 저희 모델의 핵심인 Dual Input Stream, 즉 이중 입력 구조를 설계했습니다.

일반적인 주가 예측 모델은 주가 데이터를 입력으로 사용합니다. 하지만 EDA 결과가 보여주듯이, 주가는 금리, 환율, 글로벌 경제 상황 등 외부 요인의 영향을 크게 받습니다. 그래서 저희는 **두 개의 독립적인 입력 스트림을 설계**했습니다.

첫 번째 스트림은 주식 데이터입니다.

20개 종목의 과거 90일치 종가 데이터가 입력됩니다. 형태는 90일 × 20종목입니다.

두 번째 스트림은 경제지표 데이터입니다.

27개 경제지표의 과거 90일치 데이터가 입력됩니다. 형태는 90일 × 27지표입니다.

이 두 스트림은 각각 별도로 처리된 후, **중간에서 결합(Merge)** 되어 최종 예측을 수행합니다. 이렇게 분리해서 처리하는 이유는 주가와 경제지표가 서로 다른 특성과 스케일을 가지고 있기 때문입니다. 각각의 패턴을 독립적으로 학습한 뒤 결합하는 것이 더 효과적입니다.

출력은 **20개 종목 × 7일 = 140개의 예측값**입니다. 즉, 모든 종목에 대해 1일 후부터 7일 후까지의 주가를 한 번에 예측합니다."

3개 모델 비교 (LR, LSTM, Transformer)

"저희는 이 Dual Input Stream 구조를 기반으로 **세 가지 모델을 구현하고 비교**했습니다.

첫 번째, Linear Regression입니다.

가장 단순한 베이스라인 모델입니다. 90일치 주식 데이터와 경제지표를 모두 1차원으로 펼쳐서 입력합니다. 90일 × 47개 피쳐, 총 4,230개의 입력 차원이 됩니다. 구조가 단순해서 학습이 빠르지만, 시계열의 순차적 패턴을 학습하지 못한다는 한계가 있습니다.

두 번째, LSTM입니다.

Long Short-Term Memory의 약자로, 시계열 데이터에 특화된 딥러닝 모델입니다. 주식 스트림과 경제지표 스트림 각각에 **2층의 LSTM 레이어**를 적용하고, 128개의 유닛을 사용했습니다.

두 스트림의 출력을 Concatenate로 결합한 뒤 Dense 레이어를 거쳐 최종 예측을 수행합니다.

LSTM은 **과거 정보를 기억하고 활용**하는 데 강점이 있어 시계열 예측에 널리 사용됩니다.

세 번째, Transformer입니다.

최근 자연어 처리 분야에서 혁신을 일으킨 모델로, 주가 예측에도 활용되고 있습니다. 핵심은 **Multi-Head Attention 메커니즘**입니다. 시퀀스 내 모든 위치 간의 관계를 동시에 학습할 수 있습니다.

저희는 각 스트림에 4개의 Transformer Encoder 레이어를 적용하고, 8개의 Attention Head를 사용했습니다.

두 스트림은 Add로 결합됩니다."

핵심 하이퍼파라미터 설명

"세 모델에 공통으로 적용된 핵심 하이퍼파라미터를 설명드리겠습니다.

Lookback Window는 **90일**입니다. 과거 90일의 데이터를 보고 미래를 예측합니다.

90일을 선택한 근거는, GDP 등 분기 데이터가 약 90일 주기로 발표되므로 **최소 1개의 분기 데이터 변화를 포착할 수 있고**, 약 3개월의 데이터로 단기 계절적 패턴을 학습할 수 있기 때문입니다.

Forecast Horizon은 **7일**입니다. 1일 후부터 7일 후까지의 주가를 예측합니다.

이렇게 다중 스텝 예측 방식을 채택한 이유는, 단일 모델로 다양한 예측 기간을 제공하여 투자자의 다양한 투자 기간에 대응할 수 있기 때문입니다.

딥러닝 모델의 경우, Epochs는 **50**, Batch Size는 **32**, Learning Rate는 **0.0001**을 사용했습니다. Dropout은 **0.2**를 적용하여 과적합을 방지했습니다.

데이터 활용 방식에 대해 말씀드리면, 저희는 미래 주가 예측이라는 목적에 맞게 **전체 데이터를 학습에 활용**했습니다. 가장 최신 데이터까지 학습하여 실제 미래 예측 성능을 극대화하기 위함입니다.

예측 성능 평가는 학습 완료 후 실제값과 예측값을 비교하는 방식으로 수행했습니다. 이제 이 세 모델의 성능을 어떻게 평가하고 비교했는지 설명드리겠습니다."

4. 실험 & 결과 (4분) - 발표 대본 (개선)

평가 지표 선정

"이제 세 모델의 성능을 어떻게 평가했는지 설명드리겠습니다. 저희는 **네 가지 평가 지표**를 사용했습니다.

첫째, ****MAE(Mean Absolute Error)****입니다.

예측값과 실제값 차이의 절대값을 평균한 것입니다. 원본 데이터와 동일한 단위(엔화)를 가지므로 해석이 직관적입니다. '평균적으로 얼마나 틀렸는가'를 알 수 있습니다.

둘째, ****RMSE(Root Mean Squared Error)****입니다.

오차를 제곱하여 평균한 뒤 제곱근을 취한 값입니다. MAE와 비슷하지만, 큰 오차에 더 큰 패널티를 부여합니다. 즉, 극단적으로 틀린 예측이 있으면 RMSE가 크게 증가합니다.

셋째, ****MAPE(Mean Absolute Percentage Error)****입니다.

오차를 실제값 대비 백분율로 표현한 것입니다. '평균적으로 몇 퍼센트 틀렸는가'를 알 수 있어서, 서로 다른 가격대의 종목을 비교할 때 유용합니다. 예를 들어 Toyota는 3,000엔대, Fast Retailing은 50,000엔대인데, MAPE를 쓰면 공정하게 비교할 수 있습니다.

넷째, **Accuracy**입니다.

저희는 Accuracy를 100에서 MAPE를 뺀 값으로 정의했습니다. MAPE가 5%라면 Accuracy는 95%입니다. 직관적으로 '얼마나 맞았는가'를 표현할 수 있어 결과 해석에 유용합니다.

평가 기준은 **7일 후(Day7) 예측 성능**을 주요 기준으로 삼았습니다. 실제 투자 의사결정에서 일주일 단위 예측이 실용적 가치를 갖기 때문입니다. 추가로 Day1부터 Day7까지의 평균 성능도 함께 제시하여 모델의 전반적인 예측 안정성을 확인했습니다."

모델별 성능 비교

"그럼 세 모델의 성능을 비교해 보겠습니다. **7일 후 예측 기준 결과**입니다.

****Linear Regression은 Accuracy가 거의 100%, MAPE가 거의 0%****를 기록했습니다.

예를 들어 NTT의 7일 후 MAPE는 0.0000000000000000742%, 사실상 오차가 없는 것처럼 나타났습니다.

****LSTM은 Accuracy 94.01%, MAPE 5.99%****를 기록했습니다.

종목별로 보면 NTT가 96.50%로 가장 높고, Toyota 96.25%, SMFG 96.08% 순이었습니다.

반면 Advantest는 83.13%로 상대적으로 낮았는데, 이는 반도체 종목 특유의 높은 변동성 때문입니다.

****Transformer는 Accuracy 91.36%, MAPE 8.64%****를 기록했습니다.

NTT가 96.83%로 가장 높았지만, Advantest는 58.88%로 크게 하락했습니다. LSTM보다 변동성이 큰 종목에서 더 취약한 모습을 보였습니다.

숫자만 보면 Linear Regression이 압도적으로 좋아 보이지만, **'이상하게도' 오차가조차 보이지 않는 100% 정확도가 정말 맞을까요?**

단순한 선형 모델이 이 딥러닝 모델보다 뛰어난다는 것이 직관적으로 이해되지 않았습니다. 그래서 **Bias-Variance 분석**을 진행했습니다."

Bias-Variance 분석 (LR 과적합 설명)

"Bias-Variance Tradeoff는 모델의 오차를 이해하는 핵심 개념입니다.

Bias(편향)는 모델이 너무 단순해서 데이터의 패턴을 학습하지 못하는 문제입니다. 이를 Underfitting이라고 합니다.

Variance(분산)는 모델이 너무 복잡해서 훈련 데이터에만 맞춰지는 문제입니다. 이를 Overfitting이라고 합니다.

좋은 모델은 이 둘 사이에서 균형을 찾아야 합니다. **정확도가 높다고 무조건 좋은 것이 아닙니다.**

먼저 **Linear Regression의 과적합을 증명했습니다.**

입력 데이터 구조를 보면, 90일 × 47개 피쳐 = 총 4,230개의 입력 차원입니다. 그런데 학습 샘플 수는 약 3,200개입니다. **피쳐 수가 샘플 수보다 많은 상황**에서 Linear Regression은 훈련 데이터에 거의 완벽하게 암기할 수 있습니다.

하지만 이는 패턴을 학습한 것이 아니라 데이터를 외운 것입니다.

실제 데이터를 상세히 분석해보면, Day1부터 Day7까지 예측값이 하루 사이에 50% 이상 급변하는 비현실적인 패턴이 관찰됐습니다.

다음으로 **LSTM의 Learning Curve**를 분석했습니다.

훈련 데이터 크기를 20%에서 100%까지 늘려가며 Training Loss와 Validation Loss의 변화를 관찰했습니다. 데이터가 증가함에 따라 두 Loss 사이의 Gap이 0.19에서 0.041로 줄어들었습니다.

이는 **LSTM이 적절한 Bias-Variance 균형을 이루고 있음**을 보여줍니다.

모델 복잡도에 따른 비교 분석도 수행했습니다.

LSTM 유닛 수를 16에서 256까지 변경하며 테스트한 결과, **128개 유닛에서 최적의 균형 점**에 도달했습니다. 16개는 Underfitting, 256개는 미미한 개선에 비해 복잡도가 과도하게 증가하는 패턴을 보였습니다.

종합하면, Linear Regression은 Bias가 매우 낮지만 Variance가 극도로 높아 신뢰할 수 없었습니다.

Transformer는 Bias는 낮으나 Variance가 높았습니다.

LSTM이 Bias와 Variance 모두 적절한 수준으로 가장 신뢰할 수 있는 모델이었습니다."

Hyperparameter Tuning 결과

"최적 모델로 선정된 LSTM에 대해 Hyperparameter Tuning을 수행했습니다. Sensitivity Analysis 방식으로 Baseline 설정을 기준으로 각 파라미터를 개별 변경하여 총 8개의 실험을 수행했습니다. 탐색 대상은 Lookback, LSTM Units, Dense Units, Dropout Rate, Batch Size입니다. 실험 결과, **현재 Baseline 설정(LSTM 128 units)이 1위를 기록했습니다.**

Validation Loss 0.0358로 가장 좋은 성능을 보였고, 2위인 High-Capacity 설정(0.0366)보다 우수했습니다. 하이퍼파라미터별 인사이트를 말씀드리면,

Lookback은 90일이 적절했습니다. 120일로 늘리면 오히려 노이즈 증가로 성능이 저하되었습니다.

LSTM Units은 128개가 최적이었습니다. 64개로 줄이면 성능이 저하되었습니다(Val Loss 0.0432, 최하위).

Dropout 0.2가 0.15보다 더 좋은 성능을 보였습니다.

Batch Size 32가 64보다 안정적인 학습을 제공했습니다."

결론적으로, 8가지 설정을 체계적으로 비교한 결과 **현재 Baseline 설정이 1위로 확인되었습니다**. Val Loss 0.0358로 가장 낮은 손실을 기록했으며, 이는 우리가 선택한 하이퍼파라미터 조합(LSTM 128 units, Dense 128 units, Dropout 0.2, Batch Size 32, Learning Rate 0.0001)이 최적이었음을 의미합니다.

최적 모델 선정 근거 (LSTM)

"종합하면, 저희는 **LSTM을 최적 모델로 선정**했습니다.

선정 근거를 정리하면,

첫째, 신뢰할 수 있는 정확도입니다.

94.01%의 Accuracy는 과적합 없이 달성한 실제 성능입니다.

둘째, 안정적인 예측입니다.

종목별 표준편차가 2.85%로, Transformer의 8.08%에 비해 훨씬 낮습니다. 20개 종목 모두에서 고르게 좋은 성능을 보입니다.

셋째, Bias-Variance 균형입니다.

훈련 오차와 검증 오차의 차이가 적어 새로운 데이터에도 일반화가 잘 됩니다.

넷째, 시계열 특성에 적합합니다.

LSTM의 게이트 메커니즘이 주가의 시간적 종속성을 효과적으로 학습합니다.

Transformer가 대규모 데이터에서 강점을 보이는 반면, 약 3,200개 샘플 규모에서는 LSTM이 더 적합했습니다.

Linear Regression의 100%는 환상이었고, LSTM의 94%가 진짜였습니다.

높은 숫자가 항상 좋은 것은 아니라는 점, 이것이 저희 실험의 핵심 교훈입니다."

5. 웹 서비스 데모 (2분) – 발표 대본

시스템 아키텍처 (FastAPI + Next.js)

"저희 프로젝트의 세 번째 목표는 실제 웹 서비스화였습니다. 예측 결과를 누구나 쉽게

확인할 수 있도록 웹 대시보드를 구축했습니다. 시스템 아키텍처는 **백엔드와 프론트엔드로 분리되어** 있습니다.

백엔드는 **FastAPI**를 사용했습니다. Python 기반의 고성능 웹 프레임워크로, 저희가 학습시킨 모델의 예측 결과를 API로 제공합니다. 총 16개의 엔드포인트를 구현했습니다. 대시보드 데이터, 종목 목록, 종목 상세, 경제지표, 모델 비교 등의 API가 있습니다.

프론트엔드는 **Next.js**를 사용했습니다. React 기반의 프레임워크로, 서버 사이드 렌더링을 지원하여 빠른 초기 로딩이 가능합니다. UI 스타일링은 Tailwind CSS, 차트 시각화는 Recharts 라이브러리를 사용했습니다. 다크모드도 지원합니다.

데이터 흐름을 간단히 설명드리면, 프론트엔드에서 API를 호출하면 백엔드가 CSV 파일에서 예측 결과를 읽어 JSON으로 반환합니다. 실시간 예측이 아니라 **사전에 학습된 모델의 예측 결과를** 서빙하는 방식입니다."

주요 기능 시연 (대시보드, 종목 비교 등)

"이제 실제 서비스 화면을 보여드리겠습니다.

첫 번째는 대시보드입니다.

메인 화면에서 모델을 선택할 수 있습니다. Transformer, LSTM, Linear Regression 중 하나를 선택하면 해당 모델의 예측 결과가 표시됩니다.

평균 정확도, MAPE, 추천 분포(Strong Buy, Buy, Sell) 등 핵심 지표를 한눈에 확인할 수 있습니다.

상승 예측 상위 종목과 하락 예측 종목도 바로 볼 수 있습니다.

두 번째는 종목 목록입니다.

20개 종목을 테이블 형태로 보여줍니다. 현재가, 7일 후 예측가, 변동률, 추천, 정확도 컬럼이 있습니다.

종목명 검색, 추천별 필터링, 컬럼별 정렬 기능을 제공합니다.

종목을 클릭하면 상세 페이지로 이동합니다.

세 번째는 종목 상세 페이지입니다.

개별 종목의 상세 예측 정보를 제공합니다.

Day1부터 Day7까지의 예측 가격을 표와 차트로 보여줍니다.

과거 30일간의 실제 주가와 예측값을 비교하는 차트도 있습니다.

세 모델의 예측 결과를 한 화면에서 비교할 수도 있습니다.

네 번째는 경제지표 페이지입니다.

27개 경제지표를 일본, 미국, 시장 세 카테고리로 분류하여 보여줍니다.

각 지표의 최근 추이를 라인 차트로 시각화했습니다.

지표별로 발표 주기가 다르기 때문에, 일간, 주간, 월간, 분기별로 기간 선택이 가능합니다.

다섯 번째는 모델 비교 페이지입니다.

세 모델의 예측 성능을 한눈에 비교할 수 있는 페이지로, 정확도, MAPE를 막대 차트로, 종목별 성능은 레이더 차트로 시각화했습니다.

추천 분포를 파이 차트로 보여주고, Linear Regression의 과적합 경고 메시지도 표시했습니다.

여섯 번째는 종목 비교 페이지입니다.

2개에서 5개까지 종목을 선택하여 동시에 비교할 수 있습니다.

과거 30일 가격 추이와 7일 후 예측값을 한 차트에서 비교할 수 있어, 투자 의사결정에 도움이 됩니다.

이렇게 전체는 모델 개발에서 끝나지 않고, 실제로 사용할 수 있는 **서비스 형태로 구현**하는 것까지 완료했습니다."

6. 향후 과제

한계점 및 개선 방향

"물론 저희 프로젝트에는 한계점도 있습니다. **첫째, 데이터 규모의 한계입니다.**

약 4,000개의 샘플은 딥러닝 모델, 특히 Transformer에게는 충분하지 않은 규모입니다. 더 많은 데이터가 있었다면 Transformer의 성능이 더 좋았을 수 있습니다.

둘째, 외부 요인의 미반영입니다.

뉴스, 기업 실적 발표, 정치적 이벤트 등 정량화하기 어려운 요소들은 모델에 반영하지 못했습니다. 실제 주가는 이러한 요인들에 크게 영향을 받습니다.

셋째, 실시간 예측이 아닙니다.

현재는 사전에 학습된 모델의 결과를 서빙하는 방식입니다. 실시간으로 데이터를 수집하고 예측하는 파이프라인은 구축되어 있지 않습니다.

향후 개선 방향으로,

첫째, 뉴스 데이터와 감성 분석을 추가하여 정성적 요인을 반영할 수 있습니다.

둘째, 실시간 데이터 파이프라인을 구축하여 매일 자동으로 예측을 업데이트할 수 있습니다.

셋째, 종목 수를 확대하여 Nikkei 225 전체 종목이나 다른 시장으로 확장할 수 있습니다.

이상으로 J-StockLab 프로젝트 발표를 마치겠습니다. 감사합니다. 질문 있으시면 받겠습니다."