

모델 학습 및 하이퍼파라미터 튜닝

Model: "functional"

Layer Type	Output Shape	Parameters Connected To	
input_layer (InputLayer)	(None, 90, 1)	0	-
input_layer_1 (InputLayer)	(None, 90, 22)	0	-
multi_head_attention	(None, 90, 1)	57	input_layer[0][0]
multi_head_attention_4	(None, 90, 22)	16,038	input_layer_1[0][0]
dropout_1	(None, 90, 1)	0	multi_head_attention[0][0]
dropout_13	(None, 90, 22)	0	multi_head_attention_4[0][0]
add	(None, 90, 1)	0	input_layer[0][0], dropout_1[0][0]
add_8	(None, 90, 22)	0	input_layer_1[0][0], dropout_13[0][0]
layer_normalization	(None, 90, 1)	2	add[0][0]
layer_normalization_8	(None, 90, 22)	44	add_8[0][0]
dense	(None, 90, 256)	512	layer_normalization[0][0]
dense_9	(None, 90, 256)	5,888	layer_normalization_8[0][0]

Layer Type	Output Shape	Parameters Connected To	
	90, 256)		
dense_1	(None, 90, 1)	257	dense[0][0]
dense_10	(None, 90, 22)	5,654	dense_9[0][0]
dropout_2	(None, 90, 1)	0	dense_1[0][0]
dropout_14	(None, 90, 22)	0	dense_10[0][0]
add_1	(None, 90, 1)	0	layer_normalization[0][0], dropout_2[0][0]
add_9	(None, 90, 22)	0	layer_normalization_8[0][0], dropout_14[0][0]
layer_normalization_1	(None, 90, 1)	2	add_1[0][0]
layer_normalization_9	(None, 90, 22)	44	add_9[0][0]
multi_head_attention_1	(None, 90, 1)	57	layer_normalization_1[0][0]
multi_head_attention_5	(None, 90, 22)	16,038	layer_normalization_9[0][0]
dropout_4	(None, 90, 1)	0	multi_head_attention_1[0][0]
dropout_16	(None, 90, 22)	0	multi_head_attention_5[0][0]

Layer Type	Output Shape	Parameters Connected To	
add_2	(None, 90, 1)	0	layer_normalization_1[0][0], dropout_4[0][0]
add_10	(None, 90, 22)	0	layer_normalization_9[0][0], dropout_16[0][0]
layer_normalization_2	(None, 90, 1)	2	add_2[0][0]
layer_normalization_10	(None, 90, 22)	44	add_10[0][0]
dense_2	(None, 90, 256)	512	layer_normalization_2[0][0]
dense_11	(None, 90, 256)	5,888	layer_normalization_10[0][0]
dense_3	(None, 90, 1)	257	dense_2[0][0]
dense_12	(None, 90, 22)	5,654	dense_11[0][0]
dropout_5	(None, 90, 1)	0	dense_3[0][0]
dropout_17	(None, 90, 22)	0	dense_12[0][0]
add_3	(None, 90, 1)	0	layer_normalization_2[0][0], dropout_5[0][0]
add_11	(None, 90, 22)	0	layer_normalization_10[0][0], dropout_17[0][0]
layer_normalization_3	(None, 90, 1)	2	add_3[0][0]

Layer Type	Output Shape	Parameters Connected To	
	90, 1)		
layer_normalization_11	(None, 90, 22)	44	add_11[0][0]
multi_head_attention_2	(None, 90, 1)	57	layer_normalization_3[0][0]
multi_head_attention_6	(None, 90, 22)	16,038	layer_normalization_11[0][0]
dropout_7	(None, 90, 1)	0	multi_head_attention_2[0][0]
dropout_19	(None, 90, 22)	0	multi_head_attention_6[0][0]
add_4	(None, 90, 1)	0	layer_normalization_3[0][0], dropout_7[0][0]
add_12	(None, 90, 22)	0	layer_normalization_11[0][0], dropout_19[0][0]
layer_normalization_4	(None, 90, 1)	2	add_4[0][0]
layer_normalization_12	(None, 90, 22)	44	add_12[0][0]
dense_4	(None, 90, 256)	512	layer_normalization_4[0][0]
dense_13	(None, 90, 256)	5,888	layer_normalization_12[0][0]
dense_5	(None, 90, 1)	257	dense_4[0][0]

Layer Type	Output Shape	Parameters Connected To	
dense_14	(None, 90, 22)	5,654	dense_13[0][0]
dropout_8	(None, 90, 1)	0	dense_5[0][0]
dropout_20	(None, 90, 22)	0	dense_14[0][0]
add_5	(None, 90, 1)	0	layer_normalization_4[0][0], dropout_8[0][0]
add_13	(None, 90, 22)	0	layer_normalization_12[0][0], dropout_20[0][0]
layer_normalization_5	(None, 90, 1)	2	add_5[0][0]
layer_normalization_13	(None, 90, 22)	44	add_13[0][0]
multi_head_attention_3	(None, 90, 1)	57	layer_normalization_5[0][0]
multi_head_attention_7	(None, 90, 22)	16,038	layer_normalization_13[0][0]
dropout_10	(None, 90, 1)	0	multi_head_attention_3[0][0]
dropout_22	(None, 90, 22)	0	multi_head_attention_7[0][0]
add_6	(None, 90, 1)	0	layer_normalization_5[0][0], dropout_10[0][0]
add_14	(None, 90, 22)	0	layer_normalization_13[0][0], dropout_22[0][0]

Layer Type	Output Shape	Parameters Connected To	
	90, 22)		dropout_22[0][0]
layer_normalization_6	(None, 90, 1)	2	add_6[0][0]
layer_normalization_14	(None, 90, 22)	44	add_14[0][0]
dense_6	(None, 90, 256)	512	layer_normalization_6[0][0]
dense_15	(None, 90, 256)	5,888	layer_normalization_14[0][0]
dense_7	(None, 90, 1)	257	dense_6[0][0]
dense_16	(None, 90, 22)	5,654	dense_15[0][0]
dropout_11	(None, 90, 1)	0	dense_7[0][0]
dropout_23	(None, 90, 22)	0	dense_16[0][0]
add_7	(None, 90, 1)	0	layer_normalization_6[0][0], dropout_11[0][0]
add_15	(None, 90, 22)	0	layer_normalization_14[0][0], dropout_23[0][0]
layer_normalization_7 (LayerNormalization)	(None, 90, 1)	2	add_7[0][0]
layer_normalization_15 (LayerNormalization)	(None, 90, 22)	44	add_15[0][0]

Layer Type	Output Shape	Parameters Connected To	
dense_8 (Dense)	(None, 90, 64)	128	layer_normalization_7[0][0]
dense_17 (Dense)	(None, 90, 64)	1,472	layer_normalization_15[0][0]
add_16 (Add)	(None, 90, 64)	0	dense_8[0][0], dense_17[0][0]
dense_18 (Dense)	(None, 90, 128)	8,320	add_16[0][0]
dropout_24 (Dropout)	(None, 90, 128)	0	dense_18[0][0]
global_average_pooling1d (GlobalAveragePooling1D)	(None, 128)	0	dropout_24[0][0]
dense_19 (Dense)	(None, 1)	129	global_average_pooling1d[0][0]

- 모델 요약(Model Summary): Transformer를 활용하여 시계열 데이터(주가 + 경제 지표)를 동시에 처리하기 위한 구조입니다.

입력(Inputs)이 2개이며(**(None, 90, 1)**과 **(None, 90, 22)**), 각 입력에 대해 **4개의 Transformer Encoder 레이어**를 쌓아 올린 뒤, 최종적으로 **GlobalAveragePooling1D**까지 거쳐 **(None, 1)** 크기의 출력을 내는 형태입니다.

아래에서 **레이어별로** 어떤 일을 하는지, **출력 크기**, **파라미터**(Param #)가 왜 그렇게 계산 되는지 **순서대로** 설명하겠습니다.

1) 입력 레이어 (InputLayer)

- **input_layer (InputLayer): (None, 90, 1)**
 - 이 레이어는 "주가 데이터(예: QQQ ETF)"를 위한 입력입니다.
 - ****None****은 batch 크기(가변), ****90****은 lookback(시계열 길이), ****1****은 특

성 수(여기서는 한 종류의 종가만).

- **input_layer_1 (InputLayer): (None, 90, 22)**

- 이 레이어는 “경제 지표”를 위한 입력입니다.
- ****90****은 시계열 길이, ****22****는 경제 지표 특성 수(금리, 인플레이션율 등 총 22개).

파라미터(Param #): 입력 레이어 자체는 학습 파라미터가 없습니다(0).

2) Multi-Head Attention 레이어들

(예: **multi_head_attention**, **multi_head_attention_4**, ...)

모델 요약에서 보시면 ****multi_head_attention****라는 이름이 여러 번 등장합니다.

- **모델의 구조**가 주가와 경제 지표 각각에 대해 **4개의 Transformer 블록**을 쌓았기 때문에,
- 각 블록마다 **MultiHeadAttention**이 1개씩 등장하는 구조입니다.

예시: multi_head_attention (None, 90, 1)

- 입력이 **(None, 90, 1)** 형태로 들어가면, **Self-Attention**을 수행하여 같은 크기 **** (None, 90, 1) ****를 출력.
- **Param # = 57**는 query, key, value 가중치 + dense 등 합친 값.
 - 구체적으로는 **num_heads=8**이고, **key_dim=1**이지만, 내부적으로 가중치가 여러 개 생겨서 57이 됩니다.

예시: multi_head_attention_4 (None, 90, 22)

- 두 번째 입력(경제 지표)에 대해서도 동일하게 Self-Attention을 진행하는 레이어.
 - **Param # = 16,038**로 더 큰 이유는 입력 특성 수가 22로 훨씬 크기 때문에, 쪼개지고 합쳐지는 가중치가 많아집니다.
-

3) Dropout → Add → LayerNormalization

(예: **dropout_1**, **dropout_13**, **add**, **add_8**, **layer_normalization**, **layer_normalization_8**, ...)

Transformer 블록에는 **잔차 연결(Residual Connection) + Layer Normalization**이 반복적으로 등장합니다.

1. **Dropout**: Overfitting 방지를 위해 일부 뉴런 출력을 0으로 만들 확률적 기법.
2. **Add**: Self-Attention 결과와 원본 입력을 더함(Residual Connection).
3. **LayerNormalization**: 각 시점(Sequence) 내 채널 방향으로 평균/분산을 정규화.
 - **layer_normalization**과 **layer_normalization_8** 등은 서로 다른 계층(주가/경제 지표 블록별)을 의미합니다.

출력 크기 변화

- 입력과 동일한 **(None, 90, 1)** 또는 **(None, 90, 22)** 형태를 유지.
- ***Param #**가 2 또는 44 등으로 나타나는 것은 LayerNorm의 “베타, 감마” 등 파라미터 때문.

4) Feed-Forward Network: Dense → Dense

(예: **dense, dense_1, dense_9, dense_10, ...**)

각 Transformer 블록에서 Self-Attention 뒤에는 **2중 Dense(FFN)**가 존재합니다.

예시:

- **dense (Dense)**: 출력 크기가 **(None, 90, 256)**
 - 여기서 **ff_dim=256**이라서, 내부적으로 weight가 **현재 채널 수 × 256**만큼 생깁니다.
 - Param #이 512인 것은, (입력채널1×256 + bias 등)으로 계산됩니다.
- **dense_1 (Dense)**: 다시 **(None, 90, 1)**으로 줄여주거나(주가 블록 쪽), **(None, 90, 22)**로 줄여주는(경제 지표 블록 쪽) 형태.

Dropout → Add → LayerNormalization

Feed-Forward 결과도 다시 **잔차 연결(Add)**과 LayerNorm을 거치며 블록 하나가 완성.

5) 동일 패턴이 4번 반복

주가 입력(주가 블록)과 경제 지표 입력(경제 블록)에 대해, 위의 Multi-Head Attention +

FFN 구조가 **4번씩** 반복됩니다.

각 반복마다 **multi_head_attention_*, dense_*, dropout_*, add_*, layer_normalization_*** 이름이 증가하는 모습을 볼 수 있습니다.

6) 최종 병합(Merge) 후 Dense

(예: **add_16 (Add)**, **dense_18 (Dense)**, **dropout_24 (Dropout)**, **global_average_pooling1d**, **dense_19 (Dense)**)

이 부분에서는 주가 블록과 경제 지표 블록을 최종 합칩니다.

1. **add_16 (Add)**: 주가 측 마지막 출력과 경제 지표 측 마지막 출력을 **단순히 더하는**(Residual-like) 방식.
 - 출력 크기: **(None, 90, 64)**
 - 여기서 각각의 블록이 64차원으로 축소되어 있다가, 두 정보를 합칩니다.
 2. **dense_18 (Dense): (None, 90, 128)**
 - 두 블록이 합쳐진 뒤, 128 차원으로 다시 확장.
 3. **dropout_24 (Dropout)**
 - Overfitting 완화를 위해 Dropout.
 4. **global_average_pooling1d (GlobalAveragePooling1D)**
 - 시퀀스 길이(90)에 대해 평균을 내서, ****(None, 128)****로 바뀜.
 - 시계열 길이를 압축하는 단계(Flatten 대신 평균).
 5. **dense_19 (Dense): (None, 1)**
 - 마지막 출력. 예측해야 하는 타겟이 1개(QQQ ETF 주가)라서 **유닛 1**.
 - Param # = 129: 128개의 입력 가중치 + 편향 = 128 + 1 = 129.
-

7) 총 파라미터(Total params: 124,041)

- 약 12만 개 정도의 학습 가능한 가중치가 있습니다.
 - 이 중 대부분은 **Multi-Head Attention**과 **Feed-Forward** 부분에서 발생합니다.

다.

- Transformer 구조 특성상, 입력 차원이 클수록 파라미터도 크게 증가합니다(경제 지표가 22개라, 해당 블록 파라미터가 많음).

정리

- **모델 입력:** (주가 90일, 경제 지표 90일) → 각각 4번씩 Transformer 인코딩.
- **중간단계:** Multi-Head Attention, Dropout, Residual(Add), LayerNorm, Feed-Forward가 반복.
- **병합:** 두 인코딩 결과를 합치고, Dense로 변환 후 GlobalAveragePooling1D로 시계열 길이 90을 평균.
- **출력:** Dense(1)로 일주일 후 주가 1개를 예측.

이 모델은 **시계열 Transformer**의 전형적인 구조를 보여주고, 2개 입력(주가 시계열, 경제 지표 시계열)을 병렬로 처리한 뒤 **Add**로 합친 점이 특징입니다.

LayerNormalization, MultiHeadAttention 등 Transformer의 핵심 메커니즘을 모두 갖추고 있으며, 최종적으로는 ****GlobalAveragePooling1D****를 통해 시퀀스 차원을 축소해 **(Batch, Feature)** 형태로 결과를 출력합니다.

이러한 구조를 통해, 과거 90일간의 주가 흐름과 경제 지표 변화를 동시에 참고하여, **7일 후 주가**를 보다 정교하게 예측하고자 하는 것이 **모델의 목적**입니다.