



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

석사학위논문

인공지능 모델을 활용한
주가 예측성과 분석
-국제시장 비교-

Prediction Performance of Stock Price using
Artificial Intelligence Models
-Global Market Approach-



국민대학교
비즈니스IT전문대학원
트레이딩시스템전공

김 태 현

2022

인공지능 모델을 활용한 주가
예측성과 분석
-국제시장 비교-

Prediction Performance of Stock Price using Artificial
Intelligence Models
-Global Market Approach-

지도교수 최흥식

위 논문을 석사학위 청구논문으로 제출함

2022년 12월

국민대학교
비즈니스IT전문대학원
트레이딩시스템전공

김 태 현

2022



김태현의
석사학위 청구논문을 인준함

2023년 1월

 審査委員長 김 선 응 ①
審査委員 최 흥 식 ①
審査委員 안 현 철 ①

국민대학교
비즈니스IT전문대학원

목차

차례	i
그림 차례	ii
표 차례	iii
국문 요약	iv
제1장 서론	1
1.1 연구의 배경 및 목적	1
1.2 연구의 내용 및 구성	3
제2장 이론적 배경	4
2.1 전통적인 주가 예측	4
2.2 인공지능을 활용한 주가 예측	5
제3장 자료 및 연구모형	8
3.1 자료 소개	8
3.2 연구 모형	10
3.2.1 XGBoost	10
3.2.2 LSTM	12
3.2.3 CNN	16
3.3 실험 과정	19
제4장 실증 분석 결과	21
제5장 결론 및 향후 연구	23
참고문헌	24
Abstract	28

그림 차례

<그림 1> 코스피 주가지수, S&P 500, Nikkei 225의 주가 차트	8
<그림 2> 코스피 주가지수, S&P 500, Nikkei 225의 학습 데이터, 검증 데이터, 시험 데이터 분류	9
<그림 3> 부스팅 알고리즘	11
<그림 4> 경사하강법	11
<그림 5> RNN 알고리즘	13
<그림 6> LSTM 알고리즘	14
<그림 7> CNN 알고리즘	16
<그림 8> CNN 입력 데이터 이미지	17
<그림 9> 실험 과정	19



표 차례

<표 1> 국가별 수익률, 연평균 수익률, 상승일 비율	9
<표 2> 실험에 활용한 입력 변수	10
<표 3> XGBoost의 파라미터 설정	12
<표 4> LSTM의 파라미터 설정	15
<표 5> CNN의 파라미터 설정	18
<표 6> 코스피 주가지수 예측성과	21
<표 7> S&P 500 주가지수 예측성과	21
<표 8> Nikkei 225 주가지수 예측성과	22
<표 9> 투자 전략 성과	22



인공지능 모델을 활용한 주가 예측 성과분석 -국제시장 비교-

김태현

국민대학교 비즈니스IT전문대학원
트레이딩시스템전공

빅데이터의 일반화와 컴퓨팅 파워의 향상으로 여러 분야에서 인공지능 모델에 속하는 머신러닝(Machine Learning)과 딥러닝(Deep Learning)의 활용이 이어지고 있다. 이를 활용한 분야에서 금융 시장도 예외는 아니다. 불규칙하고 비선형적인 주가를 예측하기 위해 인공지능의 활용이 더욱 중요해지고 있다. 본 연구에서는 다양한 인공지능 모델들을 활용하여 국제시장의 다음날 종가 방향성을 예측하고, 그 성과를 평가하고자 한다. 주가 예측 모형으로는 그동안 예측을 위해 많이 활용되어 온 XGBoost, LSTM, CNN을 활용하였으며, 주가 자료로는 코스피 주가지수, S&P 500, Nikkei 225를 활용하여 국가 간의 분석을 실행하였다. 주가 자료의 기간은 2002년 초부터 2021년 말까지 국가별 약 5000일의 일별 종가자료를 활용하였다. 실증 분석 결과로는 모델 XGBoost의 국가별 예측 정확도가 평균 56.88(%)로 가장 높았다. 예측 정확도가 가장 높게 나타난 지수는 코스피 주가지수로, 예측 정확도 61.91(%)를 기록하였다. 분석한 결과를 토대로 실제 투자 전략에 활용하여 성과를 분석하였다. 본 연구는 최근 주식 예측에서도 활용도가 커지고 있는 다양한 인공지능 모형들을 국제 주식 시장을 통해 비교함으로써 실제 투자자들에게 도움을 줄 수 있는지를 분석하였다는 측면에서 의의가 있다.

키워드: 종가 방향성 예측 모형, 추정 오차, XGBoost, LSTM, CNN

제1장 서론

1.1 연구의 배경 및 목적

1943년 Warren McCulloch과 Walter Pitts는 뉴런들 사이에 논리가 전달되는 과정을 발견하고 이를 ‘인공 신경망’이라 지칭하였다. 이후 1950년대를 시작으로 ‘인공 지능’에 관한 구체적인 연구가 시작되었다. 다만, 당시 현저히 부족한 컴퓨팅 능력으로 인해 한계점이 명확해짐에 따라 관련 학문에 대한 관심은 점점 줄어들어 왔다. 이후 1970년대 전문가 시스템(Expert System) 프로그램이 등장하며 인공지능에 관한 재차 연구가 진행되었다. Rumelhart et al.(1986)이 역전파(Backpropagation)라는 학습 방법을 대중화시키며 1950년대 이후 두 번째 인공 신경망에 관심이 높아졌다. 하지만 이를 구현하기 위해선 고가의 하드웨어를 필요로 하였으며, 일부 특수한 상황에서만 유용한 전문가 시스템으로 인해 인공지능에 추가적인 지원이 삭감되며 다시금 연구가 등한시되었다.

이처럼 인공지능이 외면받게 되었던 두 번의 사이클을 거쳐 2010년대 알파고의 등장으로 인공지능의 관심이 재차 높아지게 되었다. 인공지능이 사람의 능력을 뛰어넘을 수 있다는 것이 각인되며 연구적 가치가 향상되었고, 이를 뒷받침 할 수 있는 컴퓨팅 파워도 현존하는 상황이다. 인공 신경망의 막대한 연산량을 GPU(Graphic Processing Unit)를 통해 학습시키는 과정은 기존 CPU(Central Processing Unit) 대비 10배 이상 빠르게 진행되기에 두 번의 인공지능의 과도기와 달리 환경적인 요소들이 구축되어 있으며, 이를 통해 다양한 산업 분야로 활용 범위가 빠르게 넓어지고 있다. 인공지능을 활용하기 위한 산업은 주식 시장이라고 예외는 아니다. 금융상품의 방향성 예측을 위해 다양한 예측 모형들이 활용되고 있으며, 현재까지도 우수한 예측 성능을 보이는 모형들이 지속하여 나타나고 있다.

이와 같이 주가 예측을 위해 다양한 연구들이 이루어지고 있음에도 불구하고, 근본적으로 주가의 예측이 가능한 것인지에 관하여 다양한 논쟁들이

존재해 왔다. Bachelier(1900)의 주가는 과거와 상관없이 움직인다는 랜덤 워크(random walk)가설과 Fama(1970)의 모든 정보는 주가의 가격에 반영 되기에 과거의 정보는 현재 주가에 아무런 영향을 줄 수 없다는 효율적 시장가설(efficient market hypothesis)은 주가 예측의 불가능을 주장하는 밑바탕이 되고 있다.

반면 주가 예측은 어느 정도 가능하며 주가 예측에 활용되는 과거 변수들로 통계적 유의성을 확보할 수 있다는 주장도 존재한다. Muth(1961)는 현존하는 모든 정보를 이용해 합리적으로 상황 판단이 가능하기에 정부의 경제 정책에 대한 예상이 가능하다고 효율적 시장가설에 반하는 합리적 기대(rational expectation)가설을 주장하였다. 이처럼 Muth는 랜덤워크 가설과 효율적 시장가설에 상반되게 주가 예측이 가능하다고 주장하였으며, 이를 토대로 하여 월가(Wall Street)를 중심으로 실무에서도 다양한 예측들이 존재해 왔다. Lakonishok et al.(1994)은 PBR(Price Book-value Ratio)와 PER(Price Earning Ratio)가 낮은 가치주의 주가 수익률이 성장주의 주가 보다 지속하여 높은 수익률을 나타냄을 검증하고 주가 예측의 참고 지표로 활용할 수 있게 실증 검증하였다.

다만 이와 같은 전통적인 연구에서는 주가 예측에 예측력을 설명하기 위해 과거의 정보들을 토대로 기초 통계량 및 선형 모델을 활용하였으나, 특이 패턴들이 나타나는 현상들과 같이 현실적인 요인들에 대한 설득력이 부족하다는 한계점들이 존재하였다. 정용관, 윤영섭(1998)은 인공지능 모델을 활용한 주가 예측은 이와 같은 선형 모델로 추정하기 어려운 특이 패턴들의 한계에서 벗어나 비모수적 모델을 활용하여 현실적인 요인들에도 유용함을 검증하였다. 이렇듯 불규칙하고 비선형적인 주가의 예측에 있어서 인공지능 모델의 활용도는 더욱 중요해지고 있다.

본 연구에서는 주식 시장이 랜덤워크 가설과 효율적 시장가설에 상반되게 움직인다는 것과, 선형 모델의 한계를 인공지능 모델이 보완할 수 있다는 것을 전제로 인공지능이 주가 예측에도 활용될 수 있는지 검증해보고, 인공지능 모델들의 성과들을 분석해보고자 한다. 더불어 해외 주식에 투자하는 개인 투자자들을 ‘서학 개미’라고 표현할 만큼 해외 투자에 관심도가 많아

지는 시점에서, 인공지능 모델을 통해 국내외 투자 대상들을 예측하여 실무적 상황에서도 참고 지표로서의 활용될 수 있을지 가능성을 검증하였다. 이를 통해 정보가 부족한 투자자들에게 투자 가이드를 제공할 수 있을지 기대해 본다.

1.2 연구의 내용 및 구성

본 연구는 5장으로 구성된다. 2장에서는 전통적으로 주가를 예측하기 위해 선행된 문헌 연구와 인공지능 모형을 기반으로 주가 예측을 시도한 문헌들에 대해 소개한다. 3장에서는 기초 자료로 활용된 주가 지수들을 살펴본다. 이후 연구 과정에 활용되는 각 모델에 대한 소개와 더불어 주요 파라미터 설정에 관하여 소개한다. 4장에서는 연구에 활용된 인공지능 모형들의 성과를 토대로 결과를 실증 분석한다. 5장에서는 실험 결과를 토대로 본 연구의 결과와 한계점을 논의한다.



제2장 이론적 배경

2.1 전통적인 주가 예측

주가의 방향성에 대해 예측하고자 거시경제 변수들과 주식 시장의 관계를 분석하려는 연구들이 진행되어 왔다. Muth(1961)는 합리적 기대는 이용 가능한 모든 정보를 이용하여 미래에 대한 기대를 형성하는 것이라 주장하며 기대 형성을 위해 경제 주체들이 필요한 모든 정보를 사용할 수 있다는 가정을 전제하고 있다. Muth는 크게 두 가지로 기대를 정의하는데, 적응적 기대(adaptive expectation), 합리적 기대(rational expectation)로 구분된다. 적응적 기대는 기대와 실제의 차이에 의해 새로운 기대를 조정하게 된다며 예측 오차에 따라 기대를 조정한다고 나타낸다. 즉, 과거의 경험들을 통한 시행착오가 현재 기대를 형성하는데 반영된다는 것이다. $t+1$ 의 기대를 형성하는데 t 의 예상치와, t 의 예상치와 실제의 차이가 반영되는 것을 식으로 나타내면 다음과 같다.


$$P_{t+1}^e = P_t^e + \alpha(P_t - P_t^e) \quad 0 < \alpha < 1$$

다만, 다음과 같은 적응적 기대는 기대 형성에 과거의 정보만을 이용하며 그 정보의 일부만을 반영하여 항상 체계적인 오차가 존재할 수 밖에 없는 한계를 갖는다. 이에 Muth는 기대가 획득 가능한 모든 정보를 활용하여 형성될 수 있다고 주장하며, 이렇게 형성된 기대는 체계적 오차가 존재하지 않는다고 나타냈다. 기대 형성을 위해 필요한 모든 정보들은 실시간으로 이용 가능한 인터넷을 포함한 다양한 매체들을 통해 획득 가능하므로, 이를 주식 시장에 적용하여 합리적 기대가설의 가정을 수용한다 하더라도 수용 가능하다고 여겨진다.

국내에서도 주식 시장을 예측하기 위한 문헌 연구들이 다양한 방식으로 이어져 왔다. 이강희 외(1997)은 주식 시장에서 매매 타이밍을 예측하기 위해 캔들스틱 차트를 이용한 전문가 시스템을 개발하였다. 주식 가격 변동을

예측하기 위해 캔들스틱의 패턴들을 정의하고 유용성에 따라 투자 지표로 분류하여 실제 매매에 활용할 수 있는지 1992년부터 1997년의 데이터에 실증 분석하였다. 실험 결과는 평균 투자 성공률이 약 72%로 투자를 돕는 지표로 활용하기에 우수한 성과를 보였다. 이석준, 오경주(2011)는 패턴인식 알고리즘인 동적시간와핑(DTW, Dynamic Time Warping) 알고리즘을 활용하여 10분, 30분, 60분, 일별의 빈도에 유사 패턴을 찾아내어 최적의 매매 타이밍을 예측하는 분석을 진행하였다. KOSPI200 선물지수 1996년 5월 3일부터 2000년 2월 3일까지의 데이터를 단기상승, 단기하락, 대세상승, 대세하락, 천정횡보, 바닥횡보 등의 패턴을 적용시켜 실제 매매에 활용할 수 있을지 검증하였다. 이후 각 패턴과 빈도에 따라 전략들의 수익률을 분석했으며 한국에 국한되는 것이 아닌 해외 금융시장에서의 적용 가능성도 암시하였다.

이렇듯 기술적 분석을 통한 주식 시장 예측을 분석하는 문헌들이 지속하여 나타나고 있으며, Rozeff and Kinney(1976)의 문헌에 언급된 일월효과, Ashiq Ali et al.(2008)의 문헌에 언급된 이익발표 후 잔류현상(Post Earnings Announcement Drift) 등 주식 시장에서 발견되고 있는 이상현상(Anomaly)를 이용하여 주가 예측을 시도하는 문헌들도 존재한다. 정홍교, 김지영(2017)은 주가 예측을 시도하기 위해 오늘날의 거래량을 변수로 활용하기 위해선 HTS, MTS의 보급 이전과 이후를 구분 지을 필요성을 나타냈다. HTS와 MTS가 보급되며 스캘핑, 데이트레이딩 등 단기 거래의 접근성이 향상되었고, 이와 같은 단기 거래는 온전한 거래량을 반영하기에는 한계가 있기에 주가 예측을 위한 변수로 주식보유량을 활용하는 것이 적절하다는 것을 연구 결과를 통해 검증하였다. 문명덕(2020)은 ETF(Exchange Traded Fund) 주가 예측에 있어서 PBR(Price to Book Ratio)과 MDD(Max Draw Down)를 활용하여 하나의 참고 지표가 될 수 있을지 가능성을 점검하였다.

2.2 인공지능을 활용한 주가 예측

주가 예측을 위해 인공지능을 활용하는 연구들도 나타나고 있다. 최초로

인공신경망을 통해 시계열 분석을 시도했던 학자는 Lepedes and Faber(1987)로 기존 계량적인 예측기법보다 우수한 성과를 입증하였다. White(1988)은 IBM사의 일별 주식 수익성에 대한 예측을 위해 인공지능 모델을 활용하였으나, 당시 환경적인 요소와 최적화의 한계점으로 인해 성과적인 측면은 우수하게 평가받지 못하였다. 그러나 Kryzanowski et al.(1993)은 인공신경망을 이용해 개별기업의 1년 후의 주가를 예측하여 71%의 정확도를 얻으며 인공지능 모델의 성능을 검증하였다. 국내의 문헌 연구로 정용관, 윤영섭(1998)은 주가가 특이 패턴을 가질 수 있으며, 이를 추정하고 예측하는 수단으로 인공신경망을 활용하여 선형 모델을 활용한 결과보다 우수한 성과를 검증하였다.

최근 들어 컴퓨팅 파워의 성능적 향상으로 인공신경망을 활용하기에 막대한 연산량을 빠르게 처리할 수 있게 되었으며, 인공지능 모델은 2010년대 초반부터 급속도로 성장해왔다. 이후 인공지능 모델은 금융시장에서 다방면의 변수들과 성과 예측을 위해 활용되고 있으며, 각기 다른 모델들에 따라 성과를 달리하고 있다. 김명현 외(2015)는 인공지능 모델 중 K-NN(K-Nearest Neighbors) 알고리즘을 활용하여 KOSPI200 선물시장에 적용하였다. 통계적 예측 오차를 측정하는 방법론은 오차 제곱의 합을 제공 근한 RMSE(Root Mean Squared Error)를 활용하였으며, 상관계수 방법론은 실현된 KOSPI200 선물지수 값들과 유사한 값을 나타내며 평균적으로 높은 예측 정확도를 나타냈다.

이외에도 인공지능 모델들을 활용하여 주가 및 변동성과 같은 비선형적 요소들의 예측을 시도한 문헌 연구가 진행되어 왔다. 이모세, 안현철(2018)은 CNN(Convolutional Neural Network)을 활용하여 KOSPI200 주가 지수의 다음날 방향성을 예측하였다. 이를 위해 12가지 기술적 지표들을 그래프로 만들어 독립변수를 설정하였으며, 해당 기간 각각의 5일치 데이터에 적용시켜 정확도를 통해 성과를 측정하였다. 김경목 외(2021)는 SOM(Self Organizing Map) 모델을 통해 KOSPI200 주가지수의 수익률을 예측하고 포트폴리오를 구현하여 성과를 분석하였다. 독립변수로 개인, 기관, 외국인 등 투자자별 거래량 데이터를 활용하였으며, 이를 활용하여 구성한 포트폴리오는 기존 벤치마크 수익률 대비 높은 수익률을 나타냈다. 한태동(2021)

은 주가 예측에서 큰 장애 요인 중 하나로 거시 환경과 시장의 변동성이라 언급하며, 뉴스 정보와 검색 빈도 등의 감성 분석을 기술적 지표와 결합하여 변수로 활용하였다. LSTM(Lost Short-Term Memory)을 통해 조합된 변수들을 활용하여 주가를 예측하였으며, 업종별 활용된 변수들의 예측성과들을 검증하였다. 김영훈 외(2020)는 위험 기반 자산배분 모형 중 하나인 리스크 패리티(Risk Parity) 모형에 활용되는 주가의 변동성을 XGBoost(eXtreme Gradient Boosting)을 통해 예측하여, 최적화 자산배분 모형을 설계하였다. 이후, 실증 검증을 통해 설계된 포트폴리오의 성과를 분석하였다.



제3장 자료 및 연구 모형

3.1 자료 소개

<그림 1>에 제시된 것처럼, 데이터 가이드(DataGuide5)와 인베스팅닷컴(Investing.com)을 통해 얻은 코스피 주가지수, S&P 500, Nikkei 225의 시가, 고가, 저가, 종가 정보를 입력 변수로 활용하였다.



<그림 1> 코스피 주가지수, S&P500, Nikkei225의 주가 차트
(2002.01.02~2021.12.30)

1(%) 5.1

KMU

토대로 다음날의
마감할지 예측하였다

주식가격 상승

1(%) 5.1

KMU

토대로 다음날의
마감할지 예측하였다

주식가격 상승

1(%) 5.1

KMU

토대로 다음날의
마감할지 예측하였다

주식가격 상승

1(%) 5.1

KMU

토대로 다음날의
마감할지 예측하였다

주식가격 상승

1(%) 5.1

KMU

토대로 다음날의
마감할지 예측하였다

주식가격 상승



1(%) 5.1

KMU

토대로 다음날의
마감할지 예측하였다

주식가격 상승

3.2 연구 모형


본 연구에서는 XGBoost, LSTM, CNN 모델의 입력 변수로 <표 2>에 제시한 데이터 가이드(DataGuide5)와 인베스팅닷컴(Investing.com)에서 제공하는 코스피 주가지수, S&P 500, Nikkei 225의 2000년 1월 4일부터 2021년 12월 27일까지 총 20년 데이터의 시가, 고가, 저가, 종가 정보를 활용하였다. XGBoost와 LSTM은 시가, 고가, 저가, 종가의 원본 데이터를 활용하였으며 CNN은 원본 데이터를 캔들스틱(Candlestick) 그래프로 표현하여 입력 변수로 활용하였다.

<표 2> 실험에 활용한 입력 변수

No	변수명		설명
1	입력 변수	Open	Open Price
2		High	High Price
3		Low	Low Price
4		Close	Close Price


3.2.1 XGBoost

XGBoost(eXtreme Gradient Boosting)는 Chen, T. and C. Guestrin(2016)이 발표한 논문에 소개된 인공지능 모형이다. <그림 3>에 제시된 것처럼, 부스팅이란 여러 개의 의사결정나무(Decision Tree)를 조합하여 단일 모델을 순차적으로 적용하며 복원 랜덤 샘플링을 통해 회차가 거듭될수록 가중치를 넘겨주고 성능을 높여가는 모형이다. 즉, 약한 예측 모형들의 학습 오류에 가중치를 주어 다음 학습 모델에 이를 반영시켜 강한 예측 모형을 구축하는 모형이다. 부스팅은 이처럼 순차적으로 학습하여 모델을 강화하는 과정을 겪기에 느리다는 단점이 있으나, XGBoost는 병렬화를 통해 빠른 진행 속도로 캐글(<http://www.kaggle.com>)에서도 우수성을 인정받았다.



<그림 3> 부스팅 알고리즘

XGBoost는 부스팅을 사용하는 대표적인 모델로 인정받고 있으며 부스팅 중에서도 <그림 4>와 같은 경사하강법(Gradient Descent)을 활용하고 있다. 경사하강법은 제공된 함수의 극소값을 찾아 모델을 최적화하는 알고리즘이다. 주어진 함수의 기울기를 구하고 기울기가 절대값이 낮은 방향으로 이동하여 극소값에 다다를 때까지 반복하는 과정을 진행한다. 이를 통해 손실값이 허용 가능한 수준에 도달하거나 예측 정확도 등의 요소가 더이상 개선되지 않으면 학습을 멈추는 모델이다.



<그림 4> 경사하강법

본 연구에서 XGBoost를 통한 예측 모형은 파이썬 내에 ‘xgboost’ 라이브러리를 활용하여 분류하였다. XGBoost의 파라미터 설정은 <표 3>과 같이 설정하였다. 당일 주가의 상승 하락 여부를 판단하기에 이진분류 모형인 binary:logistic을 활용하였다. 부스터는 기본값인 의사결정기반모형인 gbtree로 설정하였으며 최적값을 찾기 위해 어느 정도의 학습을 진행할지를 결정하는 Learning_rate를 0.02로 설정하였다. Learning_rate의 기본값은 0.1이며 0부터 1사이의 값을 갖는다. Learning_rate가 높을 경우 과적합 발생을 일으킬 수 있으며, 낮을 경우 최적값을 찾기에 비교적 시간이 오래 소요될 수 있다. 따라서 과적합을 발생시키지 않기 위해 초기 설정에 비하여 Learning_rate를 낮게 설정하고 반복 횟수를 결정하는 n_estimators를 높게 설정해주었다. 본 연구에서는 Learning_rate를 기본값의 20%를 적용하여 n_estimators를 기본값 100의 500%인 500으로 설정하였다. 내부에서 생성할 결정 트리의 높이인 max_depth는 기본값인 6으로 설정하였다. reg_lambda와 reg_alpha는 각각 L2 정규화, L1 정규화를 나타내며 과적합을 방지하는 보수적 결과처리에 활용된다. reg_lambda는 회귀 계수의 크기를 감소시키며, reg_alpha는 불필요한 회귀 계수를 감소시키는데 활용된다. 본 연구에서는 reg_lambda를 기본값으로, reg_lambda를 기본값인 0을 1로 수정하여 절대값이 작은 회귀 계수를 일부 반영하여 진행하였다.


<표 3> XGBoost의 파라미터 설정

No	Parameter	Value
1	Objective	binary:logistic
2	Booster	gbtree
3	Learning_rate	0.02
4	max_depth	6
5	reg_lambda	1
6	reg_alpha	0
7	n_estimators	500

3.2.2 LSTM

LSTM(Long Short-Term Memory)는 RNN(Recurrent Neural


Networks)의 장기 의존성 한계를 극복하고자 Hochreiter and Schmidhuber(1997)이 제안한 딥러닝 모델이다. Rumelhart et al.(1986)에 근간을 두어, 기존 시계열 데이터를 분석하기 위한 도구로 활용되던 RNN 모델은 출력층이 입력층으로 들어가 순환하며 반복되는 순환신경망 형태를 띠었다. <그림 5>에 제시된 것처럼, x_t 를 입력값으로 A의 과정을 거쳐 h_t 의 결과를 도출하면 이를 다음 입력값으로 A의 과정을 재차 겪으며 순환하는 방식이다. 다만, 이러한 순환신경망 방식은 이전의 입력값들이 순환의 과정이 발생할수록 뒤의 입력값들에 충분히 전달되지 못하는 현상이 발생하며, 이전의 정보들을 충분히 활용하지 못하게 되는 단점이 존재하였다.



<그림 5> RNN 알고리즘

LSTM은 이러한 장기 의존성 문제를 해결하기 위해 Hochreiter and Schmidhuber(1997)이 처음 소개한 모델이다. RNN과의 차별점으로는 셀 스테이트(Cell State)들을 설정하여 장기 기억이 가능해진 부분이다. <그림 6>에 제시된 것처럼, LSTM 알고리즘의 도입부는 과거 정보를 잊기 위해 설정된 망각 게이트(Forget Gate)가 존재한다. 이전 셀 h_{t-1} 의 값이 망각 게이트에 입력되면, 현재 셀의 입력값 x_t 과 함께 sigmoid를 취해 0과 1 사이의 값을 출력한다. 이 과정에서 0에 근접할수록 망각, 1에 근접할수록 기

억하는 형식이다. 망각 게이트를 거쳐 현재 정보를 기억하기 위해 어느 가중치로 저장될지를 결정짓는 단계가 입력 게이트(Input Gate)이다. 입력 게이트에서는 이전 셀 h_{t-1} 의 값과 현재 셀의 입력값 x_t 에 sigmoid와, tanh를 취한다. Sigmoid는 0에서 1 사이의 값, tanh는 -1에서 1 사이의 값을 갖는데 각각 강도와 방향을 나타내기 위함이다. 마지막은 입력 게이트를 통해 형성된 후보값이 단기 기억과 장기 기억이 다음 셀로 넘어가기 위해 선별 과정을 거치는 출력 게이트(Output Gate)이다. 출력 게이트에서는 이전 장기 기억 C_{t-1} 에서 C_t 로 가는 입력 게이트 이후 과정에 tanh를 취하고 이전 셀 h_{t-1} 의 값과 현재 셀의 입력값 x_t 에 sigmoid를 취한 값을 곱해 비중을 결정하고 다음 셀로 넘어가게 된다.



<그림 6> LSTM 알고리즘

본 연구에서 LSTM를 통한 예측 모형은 파이썬 내에 ‘keras’ 라이브러리를 활용하여 분류하였다. LSTM의 파라미터 설정은 <표 4>와 같이 설정하였다. 콜백(Callbacks)은 모델의 체크포인트(Modelcheckpoint)와 조기종료(Earlystopping) 2가지를 설정하였다. Window_size는 30일의 데이터로 다음날의 종가의 방향성을 예측하기 위해 30으로 설정하였다. Batch_size는 모델의 파라미터들이 조정될 때 한번에 전파되는 양의 데이터로 32로 설정하였다.

이후 입력된 데이터의 활성화 여부를 결정하기 위한 활성화 함수로는 Clevert et al.(2016)에 의해 처음 발표된 ELU를 사용하였다. ELU는 선형 모형이기에 Sigmoid나 tanh과 비교했을 때 SGD(Stochastic Gradient Descent)의 최적화 속도가 빠르다는 장점이 존재한다. 최적화 함수로는 RMSProp을 사용하였다. RMSProp은 기울기를 단순 누적하는 것이 아닌, 지수 가중 이동 평균을 사용하여 가장 최근의 기울기들을 이전에 비해 큰 반영치를 부여하는 형식으로 이루어진 함수이다. 최적값을 찾기 위해 학습의 양을 결정하는 Learning_rate를 0.0002로 설정하였다. Learning_rate는 0부터 1사이의 값을 갖고, 높을수록 과적합 발생을 일으켜 기본값 0.1보다 낮은 0.2%를 적용하였다. 과적합 방지를 위해 Learning_rate를 낮게 설정하고 반복 횟수를 결정하는 n_estimators를 높게 설정해주어, 기본값 100의 500%인 500으로 설정하였다. 손실 함수로는 평균제곱오차(Mean Squared Error)를 사용하였다. 오차를 제공한 값의 평균을 의미하며, 값이 작을수록 알고리즘의 성능이 우수하다고 볼 수 있다.


<표 4> LSTM의 파라미터 설정

No	Parameter	Value
1	Window_size	30
2	Batch_size	32
3	Activation	elu
4	Optimizers	Rmsprop
5	Learning_rate	0.0002
6	Epoch	500
7	Loss_function	Mean_Squared Error

3.2.3 CNN

CNN(Convolutional Neural Network)은 Yann LeCun et al.(1989)이 제안한 구조에 토대를 두고 있다. 기존 인공지능 모델이 데이터에서 정보를 추출하여 학습이 이루어지는 것에 비해 데이터의 특징을 통하여 패턴을 파악하는 것이 모델의 특징이다.

<그림 7>에 제시된 것처럼, CNN 알고리즘은 합성곱(Convolution)과 풀링(Pooling) 과정을 거친다.




<그림 7> CNN 알고리즘

사전에 입력값(Input Data)의 $N \times N$ 크기 영역을 추출하고 또다른 행렬 형태의 가중치를 곱하여 입력값의 다른 $N \times N$ 크기 영역에 대한 합성곱을 도출한다. 이렇게 패턴을 추출하는 과정에서 데이터의 인접 부분들을 학습하며 파악한 특징을 한 장으로 도출시키는 과정을 진행하는데, 도출된 장을 합성곱 층(Convolutional Layer)라 일컬으며 하나의 압축 과정으로 볼 수 있다. 이와 같은 합성곱 과정을 거친 후 층(Layer)의 크기를 줄여주는 과정을 겪는 과정이 풀링(Pooling)에서 진행된다. 단순히 크기를 줄이고 미세한

부분에 일관적인 특징을 부여하는 과정이 해당 과정에서 진행된다. 하나의 이미지는 수많은 픽셀의 집합이기에 각각의 픽셀을 입력값으로 학습시키기에는 연산에 무리가 있을 수 있다. 따라서 2차원 입력값을 정사각 형태로 N 등분하여 가장 대표성 있는 값을 도출한다. 각 영역에서 가장 큰 값을 도출하는 맥스 풀링(Max Pooling)과 평균의 값을 도출하는 평균 풀링(Average Pooling)이 대표적이다.

합성곱 과정과 풀링 과정을 진행하고 나면, 평평하게 하는 과정(Flatten)을 진행하는데 이는 도출된 결과물을 일렬로 배치하는 과정을 나타낸다. 이렇게 특징을 찾는 과정을 진행하고 나면 이후 특징을 입력 데이터로 분류 과정을 진행한다. 이를 위해, 이전 과정을 통해 처리된 결과 데이터를 가진 모든 노드를 연결하여 하나 혹은 그 이상의 완전 연결 계층(Fully Connected Layer)를 적용한다. 최종적으로 결과물을 얻기 위해 특정 조건을 만족하면 다음 노드로 보내 활성화시키는 활성화 함수(Activation Function)를 적용하는 과정을 진행한다.

본 연구에서 CNN을 통한 예측 모형은 파이썬 내에 'keras' 라이브러리를 활용하여 분류하였다. CNN의 파라미터 설정은 <표 5>과 같이 설정하였다. 기존 수치를 통해 입력값을 인식했던 XGBoost와 LSTM과는 다르게 CNN은 이미지를 통해 입력값을 인식하기에 <그림 8>에 제시된 것처럼 데이터를 이미지로 만들어 입력값을 생성하였다.



<그림 8> CNN 입력 데이터 이미지

콜백(Callbacks)은 모델의 체크포인트(Modelcheckpoint)와 조기종료(Earlystopping) 2가지를 설정하였다. Window_size는 30일의 데이터로 다음날의 종가의 방향성을 예측하기 위해 30으로 설정하였다. Batch_size는 모델의 파라미터들이 조정될 때 한번에 전파되는 양의 데이터로 32로 설정하였다.


이후 입력된 데이터의 활성화 여부를 결정하기 위한 활성화 함수로는 Nair and Hinton(2010)에 의해 처음 발표된 ReLu(Rectified Linear unit)를 사용하였다. ReLu는 선형 모형이기에 Sigmoid나 tanh과 비교했을 때 SGD(Stochastic Gradient Descent)의 최적화 속도가 빠르다는 장점이 존재한다. ReLu는 입력값이 0보다 작으면 0, 0보다 큰 입력값일 경우 그대로 출력하는 활성화 함수이다. 최적값을 찾기 위해 학습의 양을 결정하는 Learning_rate를 0.0001로 설정하였다. Learning_rate는 0부터 1사이의 값을 갖고, 높을수록 과적합 발생을 일으켜 기본값 0.1보다 낮은 0.1%를 적용하였다. 과적합 방지를 위해 Learning_rate를 낮게 설정하고 반복 횟수를 결정하는 n_estimators를 높게 설정해주어, 기본값 100의 500%인 500으로 설정하였다. 최적화 함수로는 RMSProp을 사용하였다. RMSProp은 기울기를 단순 누적하는 것이 아닌, 지수 가중 이동 평균을 사용하여 가장 최근의 기울기들을 이전에 비해 큰 반영치를 부여하는 형식으로 이루어진 함수이다. 손실 함수로는 평균제곱오차(Mean Squared Error)를 사용하였다. 오차를 제곱한 값의 평균을 의미하며, 값이 작을수록 알고리즘의 성능이 우수하다고 볼 수 있다.

<표 5> CNN의 파라미터 설정

No	Parameter	Value
1	Window_size	30
2	Batch_size	32
3	Activation	relu
4	Optimizers	RMSProp
5	Learning_rate	0.0001
6	Epoch	500
7	Loss_function	Mean_Squared Error

3.3 실험 과정

실험 과정에 대한 설명은 <그림 9>에 제시된 순서로 진행되었다. 본 연구에서는 입력 변수로 2002년부터 2021년 동안의 코스피 주가지수, S&P 500, Nikkei 225 시가, 고가, 저가, 종가 데이터를 활용하였다.



<그림 9> 실험 과정

데이터의 일관성을 유지하고 모델을 단순화시키기 위해 최소-최대 정규화 (Min-Max Normalization) 과정을 선행하였으며, 학습 데이터, 검증 데이터, 시험 데이터로 데이터를 분류하여 실험하였다. 분류된 데이터들은 상기 제시된 인공지능 모델들을 활용하여 정확도, 손실값, F1스코어를 통해 비교, 분석하였다. F1 스코어는 Xia et al.(2017)의 상품 분류에 있어서 유의미한 성능을 검증한 평가 척도로, 분류 정밀도와 재현율의 평균으로 수식으로 나타내면 다음과 같다.

$$Precision(\text{정밀도}) : \frac{True\ Positives}{True\ Positives + False\ Positives}$$

$$Recall(\text{재현율}) = \frac{True\ Positives}{True\ Positives + False\ Negatives}$$

$$F1 = 2 \cdot \frac{1}{\frac{1}{Precision} + \frac{1}{Recall}} = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$



제 4장 실증 분석 결과

코스피 주가지수에 XGBoost, LSTM, CNN의 예측성과로는 <표 6>에 제시된 것처럼, XGBoost가 정확도 0.6191, 손실값 0.5557, F1 스코어 0.7332으로 세가지 비교척도 모든 항목에서 가장 우수한 정도를 나타냈다.

<표 6> 코스피 주가지수 예측성과

	정확도	손실값	F1 스코어
XGBoost	0.6191	0.5557	0.7332
LSTM	0.5519	0.6880	0.5802
CNN	0.4320	0.6861	0.6033

S&P 500 주가지수의 XGBoost, LSTM, CNN의 예측성과로는 <표 7>에 제시된 것처럼, XGBoost가 정확도 0.5777, 손실값 0.6290, F1 스코어 0.7323로 세가지 비교척도 모든 항목에서 가장 우수한 정도를 나타냈다.

<표 7> S&P 500 주가지수 예측성과

	정확도	손실값	F1 스코어
XGBoost	0.5777	0.6290	0.7323
LSTM	0.4970	0.6829	0.5273
CNN	0.4322	0.6866	0.6035

Nikkei 225 주가지수의 XGBoost, LSTM, CNN의 예측성과로는 <표 8>에 제시된 것처럼, XGBoost가 정확도 0.5096, 손실값 0.5573, F1 스코어 0.6676으로 세가지 비교척도 모든 항목에서 가장 우수한 정도를 나타냈다.

<표 8> Nikkei 225 주가지수 예측성과

	정확도	손실값	F1 스코어
XGBoost	0.5096	0.5573	0.6676
LSTM	0.4928	0.6941	0.4897
CNN	0.4415	0.6910	0.6125

실증 분석 결과를 토대로 가장 우수한 성과를 보인 XGBoost 모델을 활용하여 코스피 주가지수에 두가지 전략을 가정하고 활용하지 않은 전략과 비교했을 때, 성과 비교는 <표 9>와 같다. 비교 전략으로는 시험 데이터 기간 중, 단순 코스피 주가지수의 롱 포지션을 보유하고 있는 상황을 Long 보유 전략, XGBoost를 활용한 다음날 증가 방향성 예측에 기반하여 오를 것이라 예상한 날은 롱 포지션을, 그렇지 않은 날에 숏 포지션을 취하는 상황을 XGBoost Long & Short 전략, 그리고 XGBoost를 활용한 다음날 증가 방향성 예측에 기반하여 오를 것이라 예상한 날에 롱 포지션을, 그렇지 않은 날에 포지션을 취하지 않는 상황을 XGBoost Long 전략으로 가정하였다. 비교 항목은 각 전략의 일 평균 수익률과 기간 종료 시점의 누적 수익률, Sharpe(1966)에 의해 개발된 리스크 대비 투자 결과 성능 측정 방법인 샤프지수, 일정기간 중 최대 손실 낙폭을 나타내는 MDD(Maximum Draw Down)을 활용하였다. 샤프지수의 무위험 수익률은 CD 91일물 금리로 활용하였다. 일 평균 수익률, 누적 수익률, 샤프지수에서 Long 보유 전략이 가장 우수한 성과를 나타냈으며 MDD 항목에서 XGBoost Long 전략이 가장 우수한 성과를 나타냈다.

<표 9> 투자 전략 성과

	Long 보유 전략	XGBoost Long & Short 전략	XGBoost Long 전략
일 평균 수익률	0.11(%)	0.07(%)	0.08(%)
누적 수익률	57.78(%)	39.05(%)	49.65(%)
샤프지수	1.6450	1.0680	1.3190
MDD (Maximum Draw Down)	-31.92(%)	-32.06(%)	-28.90(%)

제 5장 결론 및 연구의 한계점

본 연구는 이상의 실험을 통해 인공지능 모델에 한국의 코스피 주가지수, 미국의 S&P 500, 일본의 Nikkei 225 주가 시계열 데이터를 활용하여 주가 예측성과를 비교 분석하였다. 주어진 데이터를 통해 의사결정나무를 기반으로 부스팅 알고리즘을 활용하여 분류 모델로 활용되었던 XGBoost, 이미지 학습을 통해 T+1일의 주가 방향성 패턴을 예측하는 CNN, 기존 순환신경망의 장기 의존성 한계를 보완하여 시계열 데이터에 적합한 모델로 여겨지는 LSTM 각각의 정확도, 손실값, F1 스코어를 성과 척도로 예측성과를 비교하였다.

분석 결과 세가지 모델 중 모든 항목에서 XGBoost가 우수한 정도를 나타냈다. XGBoost는 기본적인 모델의 설계가 이진 분류에 최적화 되어있기에, 일봉 데이터의 방향성을 예측하기에 적합한 모델로 나타났다. 더불어 입력값이 20년이라는 장기간의 데이터임에도 불구하고 일봉 데이터를 활용하였기에 데이터의 크기가 다른 모델들의 우수한 성과를 보이기 위한 학습량으로는 부족하게 평가받을 수 있을 것이다. 다만, XGBoost는 이처럼 부족하게 평가받을 수 있는 학습량에도 불구하고 과적합 규제와 자체적으로 교차 검증의 기능들을 포함하기에 CNN, LSTM에 비하여 각각의 비교 항목에서 우수한 성과를 보여주었다.

마지막으로, XGBoost의 투자 전략 활용을 통한 성과 분석은 코스피 주가지수 Long 보유 전략이 일 평균 수익률, 누적 수익률, 샤프지수에서 우수한 성과를 보였으나, XGBoost Long 전략에서 가장 높은 MDD 수치를 보였다. 이러한 XGBoost를 활용한 전략은 리스크 회피 성향이 강한 투자자들에게 하나의 참고 전략으로 활용될 수 있을 것이다. 향후 연구에서는 본 연구를 통해 검증한 일봉 데이터의 예측성과 비교에 더하여 분봉 데이터, 주봉 데이터 등 다양한 데이터 크기에 따른 예측성과 비교와, 기초 통계량을 활용한 입력값들을 설정하여 인공지능 모형들의 성과들을 상세하게 비교 분석해보고 투자 전략으로 활용될 수 있을지 실증 검증해보고자 한다.

참고문헌

[국내 문헌]

1. 권대책, 강보영(2017), “합성곱 신경망 사용을 위한 CPU와 GPU 성능 분석”, *한국정보기술학회논문지*, 제15권, 제8호, pp. 11-18.
2. 김경목, 김선웅, 최흥식(2021), “투자자별 거래정보와 머신러닝을 활용한 투자전략의 성과”, *지능정보연구*, 제27권, 제1호, pp. 65-82.
3. 김명현, 이세호, 신동훈(2015), “K-Nearest Neighbors(K-NN) 알고리즘을 통한 KOSPI200 선물지수 예측효과 연구”, *대한경영학회지*, 제28권, 제10호, pp. 2613-2633.
4. 김선웅(2022), “LSTM 기반 COVID-19 공포지수의 주가 예측 성과: 언택트 주식과 콘택트 주식”, *한국콘텐츠학회논문지*, 제22권, 제8호, pp. 329-338.
5. 김영훈, 최흥식, 김선웅(2020), “XGBoost를 활용한 리스크패리티 자산배분 모형에 관한 연구”, *지능정보연구*, 제26권, 제1호, pp. 135-149.
6. 문명덕(2020), “ETF 마켓타이밍과 트레이딩 전략에 관한 3편의 실증분석 연구”, *석사학위논문*, 국민대학교 대학원.
7. 이강희, 양인실, 조근식(1997), “캔들스틱 분석을 이용한 주식 매매 타이밍 예측을 위한 전문가 시스템”, *한국전문가시스템학회지*, 제3권, 제2호, pp. 57-70.
8. 이모세(2019), “효과적인 입력변수 패턴 학습을 위한 시계열 그래프 기반 합성곱 신경망 모형 주식시장 예측에의 응용”, *지능정보연구*, 제24권,

제1호, pp. 167-181.

9. 이석준, 오경주(2011), “선물시장의 시스템트레이딩에서 동적시간와핑 알고리즘을 이용한 최적매매빈도의 탐색 및 거래전략의 개발”, *한국데이터정보과학회지*, 제22권, 제2호, pp. 255-167.

10. 정용관, 윤영섭(1998), “인공신경망모형을 이용한 주가의 예측가능성에 관한 연구”, *한국재무관리학회*, 제15권, 제2호, pp. 369-399.

11. 정홍교, 김지영(2017), “주식보유량과 거래량의 주가예측력 비교”, *한국경영컨설팅학회*, 제17권, 제4호, pp. 127-138.

12. 한태동(2021), “LSTM을 이용한 주가 예측: 기술 지표, 거시 경제 지표, 시장 심리의 조합을 중심으로”, *융복합지식학회논문지*, 제9권, 제4호, pp. 189-198.

13. 최성섭(2012), “한국 주식시장의 일월효과에 관한 연구”, *한국상업교육학회*, 제26권, 제3호, pp. 313-332.

[국외 문헌]

1. Ali, A., X. Chen, T. Yao, and T. Yu(2008), “Do mutual funds profit from the accruals anomaly?,” *Journal of Accounting Research*, Vol. 46, No. 1, pp. 1-26.

2. Bachelier, L(1900), *Theory of Speculation*, English Translation by Cootner (1964).

3. Chen, T. and C. Guestrin(2016), “XGBoost: A scalable tree boosting system,” *22nd ACM SIGKDD Conference on Knowledge*

Discovery and Data Mining, pp. 785-794.

4. Clevert, D., T. Unterthiner, S. Hochreiter(2016), "Fast and accurate deep network learning by exponential linear units (ELUs)," *Published as a conference paper at ICLR 2016*.

5. Hochreiter, S. and J. Schmidhuber(1997), "Long short-term memory," *Neural computation*, Vol. 9, No. 8, pp. 1735-1780.

6. Kryzanowski, L., M. Galler, and W. W. David(1993), "Using Artificial neural networks to pick stocks," *Financial Analysts Journal*, Vol. 49, No. 4, pp. 21-27.

7. LeCun, Y., B. Boser, J. S. Denker, D. Henderson, R. E. Howard, W. Hubbard, and L. D. Jackel(1989), "Backpropagation applied to handwritten zip code recognition," *Neural Computation*, Vol. 1, No. 4, pp. 541-551.

8. Lakonishok, J., A. Shleifer, and R. W. Vishny(1994), "Contrarian investment, extrapolation, and risk," *The Journal of Finance*, Vol. 49, No. 5, pp. 1541-1578.

9. Lepedes, A and R. Faber(1987), "Nonlinear signal processing using neural networks : Prediction and system modeling," *Los Alamos National Laboratory Report*, LA-UR-87-2662.

10. Muth, J, F(1960), "Optimal properties of exponentially weighted forecasts," *Journal of the American Statistical Association*, Vol. 55, pp. 299-306.

11. Nair, V. and G. E. Hinton(2010), "Rectified linear units improve restricted Boltzmann machines," *27th International Conference on*

Machine Learning, pp. 807-814.

12. Rogalski, R. J. and S. M. Tinic(1986), "The January size effect: Anomaly or risk mismeasurement?," *Financial Analysis Journal*, Vol. 11, pp. 63-71.

13. Rozeff, M. S. and W. Kinney(1976), "Capital market seasonality: The case of stock returns," *Journal of Financial Economics*, Vol. 3, No. 4, pp. 379-402.

14. Rumelhart, D. E., G. E. Hinton, and R. J. Williams(1986), "Learning representations by back-propagating Errors," *Nature*, Vol. 323, pp. 533-536.

15. Sharpe, W. F(1966), "Mutual fund performance," *The Journal of Business*, Vol. 39, No. 1, pp. 119-138.

16. White, H(1988), "Economic prediction using neural networks : The case of IBM stock prices," *IJCNN*, Vol. 2, pp. 451-458.

17. Xia, Y., A. Levine, P. Das, G. Di Fabbri, K. Shinzato, and A. Datta(2017), "Large-scale categorization of Japanese product titles using neural attention models," *15th Conference of the European Chapter of the Association for Computational Linguistics*, Vol. 2, pp. 663-668.

Abstract

Prediction Performance of Stock Price using Artificial Intelligence Models -Global Market Approach-

by Kim, tae hyun

Department of Trading Systems
Graduate school of Business-IT,
Kookmin University,
Seoul, Korea



With the generalization of big data and the improvement of computing power, machine learning and deep learning belonging to artificial intelligence models are continuing to be used in various fields. Financial markets are no exception in the field of utilizing this. The use of artificial intelligence is becoming more important to predict irregular and nonlinear stock prices. This study aims to predict the direction of the closing price of the international market the next day and evaluate its performance using various artificial intelligence models. XGBoost, LSTM, and CNN, which have been widely used for prediction, were used as stock price prediction models, and cross-country analysis was conducted through the KOSPI Stock Index, S&P 500, and Nikkei 225 as stock price data. For the period of stock price data, about 5000 days of daily closing price data by country were used from the beginning of 2002 to the end of 2021. As a result of empirical

analysis, XGBoost's prediction accuracy by country was the highest among the models with an average of 56.88 (%). The index with the highest prediction accuracy was the KOSPI stock index, with a prediction accuracy of 61.91 (%). Based on the analysis results, the performance was analyzed by using it in the actual investment strategy. This study is meaningful in that it analyzes whether it can help actual investors by comparing various artificial intelligence models, which have been increasingly utilized in recent stock price predictions, to the international stock market.

Keywords: Closing Price Direction Prediction Model, Estimation Error, XGBoost, LSTM, CNN

